Confidence interval

Two numerical columns

import pandas as pd

2

3

4

```
In [17]:
           import scipy.stats as st
           data = pd.read csv('star dataset.csv')
In [18]:
           data.head()
In [19]:
Out[19]:
                Temperature
                                                                          Absolute
                                                                                                  Star
                                                                                                            Spectral
                             Luminosity(L/Lo) Radius(R/Ro)
                                                                                    Star type
                         (K)
                                                                    magnitude(Mv)
                                                                                                 color
                                                                                                               Class
                                                                                        Red
          0
                       3068
                                     0.002400
                                                     0.1700
                                                                             16.12
                                                                                                   Red
                                                                                                                 Μ
                                                                                       Dwarf
                                                                                        Red
          1
                       3042
                                     0.000500
                                                     0.1542
                                                                             16.60
                                                                                                  Red
                                                                                                                 Μ
                                                                                       Dwarf
                                                                                        Red
```

0.1020

0.1600

0.1030

Er is niet echt een normal distribution te vinden in ongefilterde kolommen, dus ga ik kijken naar waarden gefilterd op hun type of hun kleur (zoals ook in assignment 07 te zien is).

18.70

16.65

20.06

Dwarf

Red

Red

Dwarf

Dwarf

Red

Red

Red

Μ

Μ

Μ

Temperatuur voor rode sterren

2600

2800


1939

0.000300

0.000200

0.000138

```
filtered T data = data[data['Star color'] == 'Red']['Temperature (K)']
In [38]:
         filtered T data.plot(kind='hist')
         <AxesSubplot:ylabel='Frequency'>
Out[38]:
```




Het vergroten van de confidence maakt het interval natuurlijk ook groter, aangezien je zekerder wilt zijn dat een waarde die je tegenkomt binnen dit interval ligt.

Naast dat het gemiddelde veranderd is door de kleinere set, is ook de confidence interval groter geworden. Dit is logisch omdat minder waarden minder zekerheid geven dat een waarde binnen dat interval valt.

Radius voor hyper giants

```
In [46]: filtered_R_data = data[data['Star type'] == 'Hyper Giant']['Radius(R/Ro)']
    filtered_R_data.plot(kind='hist')
Out[46]: <AxesSubplot:ylabel='Frequency'>
```



```
print('Mean: ' + str(filtered R data.mean()))
In [40]:
        print('90% confidence: ' + str(st.t.interval(0.9, len(filtered R data)-1, loc=filtered R
        print('95% confidence: ' + str(st.t.interval(0.95, len(filtered R data)-1, loc=filtered
        print('99% confidence: ' + str(st.t.interval(0.99, len(filtered R data)-1, loc=filtered
        print('99.99% confidence: ' + str(st.t.interval(0.9999, len(filtered R data)-1, loc=filt
        Mean: 1366.8975
        90% confidence: (1298.8154055460816, 1434.9795944539185)
        95% confidence: (1285.1650130576531, 1448.629986942347)
        99% confidence: (1257.4766895198413, 1476.3183104801587)
        99.99% confidence: (1191.8189402201092, 1541.9760597798909)
In [49]:
        smaller set = filtered R data[:int((len(filtered R data)/10))]
        print('Count: ' + str(len(smaller set)))
        print('Mean smaller set: ' + str(smaller set.mean()))
        print('95% confidence on a smaller set: ' + str(st.t.interval(0.95, len(smaller set)-1,
```

95% confidence on a smaller set: (1055.8746058225681, 1749.6253941774319)

Count: 4

Mean smaller set: 1402.75